

Bitacora de decisiones: limpieza de datos

Proyecto final · Ciencias de Datos con Python · Aguas superficiales CONAGUA 2020

Fecha: 20 de septiembre de 2026 · 4:00pm-5:00pm · Modalidad: equipo

Integrantes: Aaron Chock Chock (achockc@ucenfotec.ac.cr), Charles Quesada Sandi (cquesadasa@ucenfotec.ac.cr), Marvin Jesús Calvo Acuña (mcalvoa@ucenfotec.ac.cr)

1. Que encontramos en el archivo

En el archivo

Datos_de_calidad_del_agua_de_sitios_de_monitoreo_de_aguas_superficiales_2020.csv detectamos columnas que mezclan cadenas de texto (string) y numeros decimales (float). Por eso hace falta limpiar antes de calcular media, mediana, boxplot o correlacion.

El problema no esta en toda la base. Esta en las variables de laboratorio que CONAGUA usa para evaluar la calidad del agua. En una misma columna pueden convivir un numero (6 o 4.26), un valor censurado (<2) y un vacio o ND.

2. Columnas de laboratorio que se convierten

Estas columnas se pasan por la funcion a_numero. No se aplica LD/2 a SEMAFORO, ESTADO, GRUPO ni a las banderas CUMPLE_CON_*.

Columna	Que mide
DBO_mg/L	Demanda bioquimica de oxigeno
DQO_mg/L	Demanda quimica de oxigeno
SST_mg/L	Solidos suspendidos totales
COLI_FEC_NMP_100mL	Coliformes fecales
E_COLI_NMP_100mL	E. coli
ENTEROC_NMP_100mL	Enterococos
OD_PORC	Oxigeno disuelto (%)
OD_PORC_SUP	Oxigeno superficial
OD_PORC_MED	Oxigeno a media profundidad
OD_PORC_FON	Oxigeno de fondo
TOX_D_48_UT	Toxicidad
TOX_V_15_UT	Toxicidad
TOX_D_48_SUP_UT	Toxicidad superficial
TOX_FIS_SUP_15_UT	Toxicidad

En el EDA (histogramas, describe, boxplot y correlaciones) usamos un subconjunto con suficientes datos: DBO, DQO, SST, coliformes, E. coli, enterococos, OD_PORC y OD_PORC_SUP. Oxigeno profundo y toxicidad se convierten, pero casi siempre estan vacias.

3. Ejemplo: DBO_mg/L (captura de Excel)

DBO_mg/L es el caso mas claro: en la misma columna hay 6, <2, 4.26 y 6.4. <2 no es el valor 2; significa que la medicion esta por debajo del limite de deteccion (LD = 2).

DBO_mg/L	CALIDAD_DBO	DQO_mg/L
6	Buena calidad	54.08
<2	Excelente	<10
<2	Excelente	<10
4.26	Buena calidad	27.98
<2	Excelente	<10
<2	Excelente	<10
6.4	Aceptable	<10
<2	Excelente	<10
<2	Excelente	<10
<2	Excelente	<10

Captura 1. Columna DBO_mg/L en Excel: se ven juntos <2, 6, 4.26 y celdas vacias.

Valor en el Excel / CSV	Tipo	Despues de limpiar
6	Numero	6.0
4.26 / 6.4	Flotante	4.26 / 6.4 (se deja)
<2	Texto censurado (menor que el LD)	1.0 (LD/2 = 2/2)
vacio o ND	No se midio	NaN (no se inventa un numero)

4. El mismo problema en otras columnas (capturas de Excel)

No es solo DBO. DQO y SST mezclan <10 con flotantes; E. coli y enterococos mezclan <3 con enteros grandes. Abajo van las capturas del Excel.

DBO_mg/L	CALIDAD_DBO	DQO_mg/L
6	Buena calidad	54.08
<2	Excelente	<10
<2	Excelente	<10
4.26	Buena calidad	27.98
<2	Excelente	<10
<2	Excelente	<10
6.4	Aceptable	<10
<2	Excelente	<10
<2	Excelente	<10
<2	Excelente	<10

Captura 2. DQO_mg/L: <10 junto a valores como 54.08 o 17.91.

DQO_mg/L	CALIDAD_DQO	SST_mg/L	CALIDAD_SST
54.08	Contaminada	13.75	Excelente
		<10	Excelente
		<10	Excelente
		13.9667	Excelente
		<10	Excelente
		22.0667	Excelente
		13.9667	Excelente
		57.85	Buena calidad
<10	Excelente	33.9	Buena calidad
<10	Excelente	25.6	Buena calidad
27.98	Aceptable	14	Excelente
<10	Excelente	<10	Excelente
<10	Excelente	<10	Excelente
<10	Excelente	<10	Excelente
<10	Excelente	<10	Excelente
<10	Excelente	<10	Excelente
		<10	Excelente
		19.5333	Excelente
<10	Excelente	10.1	Excelente

Captura 3. SST_mg/L: <10 junto a flotantes (13.75, 13.9667).

E_COLI_NMP_100mL	CALIDAD_E_COLI	ENTEROC_NMP_100mL
98	Excelente	20
		<3
		<3
		30
		<3
		90
		402
512	Buena calidad	
<3	Excelente	
84	Excelente	
538	Buena calidad	
<3	Excelente	
14136	Fuertemente contaminada	
<3	Excelente	
74	Excelente	
		<3
		<3
368	Buena calidad	

Captura 4.E_COLI o ENTEROC: <3 junto a conteos altos y celdas vacías.

5. Decisiones de limpieza

La rubrica pide buscar nulos, detectar datos mal escritos y sustituir valores. Reglas que aplicamos:

Caso	Decision	Por que
ND o celda vacia	Se pasa a NaN	No se midio. No inventamos un valor.
<LD (ej. <2, <10, <3)	LD / 2. <2 es "menos que el límite" → usamos la mitad (LD/2).	Convencion de laboratorio para datos censurados. No es la medicion real; permite EDA numerico.
>LD (ej. >100)	Se usa el numero del limite. >100 es "más que el límite" → usamos el 100.	Se pierde que era mayor que; queda anotado aqui.
Numero o flotante (6, 4.26)	Se deja como float	Ya es una medicion.
Fila sin CLAVE, sin lat/lon o sin SEMAFORO	Se elimina	No es un sitio usable. Lat/lon y semaforo NO se imputan.

LD/2 no se aplica a toda la base ni a todas las celdas de esas columnas: solo a las celdas que empiezan con <.

Usamos sustitución de datos censurados: LD/2 cuando el valor es menor que el límite, y el propio límite cuando es mayor. Es una convención válida para poder hacer EDA; no afirmamos que esa sea la concentración verdadera.

Otra sustitución habitual es **LD/V2** (aproximadamente $0.707 \times \text{LD}$). Se usa sobre todo cuando se supone que las concentraciones son lognormales, para reducir un poco el sesgo de la media. En este proyecto aplicamos **LD/2** por ser la convención más directa y fácil de explicar: si el laboratorio reporta <2 , el valor usado es 1. Ninguna de las dos fórmulas es la medición real; ambas sirven solo para poder hacer el EDA numérico. No implementamos LD/V2.

6. Que no hacemos

El laboratorio1 lista cuatro formas de tratar nulos. No se usan las cuatro; son alternativas.

Opcion del Lab 1	La usamos?	Decision del equipo
Borrar toda fila con algun nulo	No	Perderiamos costeros (sin DBO) y muchos rios (sin enterococos).
Borrar toda columna con algun nulo	No	Tirariamos DBO, DQO, coliformes y oxigeno.
Imputar con mediana / media / constante	Solo en el Pipeline de calidad	Mediana en variables de EDA, como el Lab 1. Esa matriz NO entra a K-means.
Imputar y agregar columna flag	No	El enunciado no lo pide.

7. Nulos que quedan: comprobarlos por GRUPO

Despues de convertir, siguen faltando mediciones. Antes de afirmar que un tipo de agua no midio un parametro, se cruza el % de nulos con GRUPO (COSTERO, LOTICO, LENTICO).

***	DBO_mg/L	DQO_mg/L	SST_mg/L	COLI_FEC_NMP_100mL	E_COLI_NMP_100mL	ENTEROC_NMP_100mL	OD_PORC	OD_PORC_SUP
GRUPO								
COSTERO	91.3	91.3	0.1	91.3	91.3	9.4	94.8	9.0
LENTICO	1.0	1.0	0.0	0.8	0.8	99.2	100.0	2.2
LOTICO	0.2	0.2	0.2	0.2	0.2	99.8	1.5	99.8

Captura 5 (opcional). Tabla de % nulos por GRUPO salida de Colab.

Lectura esperada (confirmar con la captura): en COSTERO falta DBO en la gran mayoría de sitios; en LOTICO y LENTICO faltan los enterococos. Eso no es un error de tipeo: no todos los grupos se miden con los mismos parametros.

8. Cierre de la seccion

La limpieza deja las mediciones de laboratorio como numeros para el EDA. El agrupamiento K-means usa solo LONGITUD y LATITUD, sin imputar. La calidad se compara despues con SEMAFORO.

¡Todos los integrantes del equipo estuvieron presentes!