



UNIVERSIDAD CENFOTEC

27 de septiembre de 2026

Proyecto final

Limpieza, análisis, visualización y K-means

Aguas superficiales CONAGUA 2020

Curso de Ciencia de Datos con Python

Prof. Jorge Ariel Bermúdez Telleria

jbermudez@ucenfotec.ac.cr

Modalidad: Equipo

Alumnos

Nombre	Correo
Charles Quesada Sandi	cquesadasa@ucenfotec.ac.cr
Aaron Chock Chock	achockc@ucenfotec.ac.cr
Marvin Jesús Calvo Acuña	mcalvoa@ucenfotec.ac.cr

Dataset

Datos de calidad del agua de sitios de monitoreo de aguas superficiales 2020 (CONAGUA)

[https://github.com/marvinjc/proyecto_final_CD/blob/373c8dc98e886cb83f683cf7a5e49a6beb8cbfa9/Datos de calidad del agua de sitios de monitoreo de aguas superficiales 2020.csv](https://github.com/marvinjc/proyecto_final_CD/blob/373c8dc98e886cb83f683cf7a5e49a6beb8cbfa9/Datos%20de%20calidad%20del%20agua%20de%20sitios%20de%20monitoreo%20de%20aguas%20superficiales%202020.csv)

[https://github.com/marvinjc/proyecto_final_CD/blob/373c8dc98e886cb83f683cf7a5e49a6beb8cbfa9/Escalas superficial.csv](https://github.com/marvinjc/proyecto_final_CD/blob/373c8dc98e886cb83f683cf7a5e49a6beb8cbfa9/Escalas_superficial.csv)

Reporte

El enunciado pide aplicar limpieza, análisis exploratorio, K-means y un mapa de México para responder si la calidad del agua superficial se relaciona con la ubicación geográfica. Se usó solo el archivo de aguas superficiales 2020. El semáforo de CONAGUA (Verde, Amarillo, Rojo) mide la calidad. K-means no lo usa para agrupar: solo recibe latitud y longitud. El semáforo se cruza después, para ver si las regiones se parecen en calidad.

1. Limpieza de datos

El archivo original tiene 4,141 filas y 55 columnas. Se eliminaron 648 filas vacías, sin clave de sitio. El análisis queda con 3,493 sitios que sí tienen coordenadas. El CSV en disco no se modifica: la limpieza vive en otro DataFrame.

Las mediciones de laboratorio mezclan números y texto (<2, <10, ND, valores ya numéricos). ND o celda vacía se deja como faltante: no se inventa un número. Un valor por debajo del límite de detección, como <2, se sustituye por la mitad de ese límite ($LD/2$) solo para poder calcular. Esa sustitución no es la concentración real. Un valor por encima del límite se deja en el número del límite.

Los faltantes no están al azar. Dependen del tipo de cuerpo de agua (GRUPO). En la costa casi no se registra DBO, DQO, coliformes ni E. coli. En ríos y lagos casi no se registran enterococos, porque CONAGUA los mide sobre todo en agua de mar. Por eso no se borra toda fila o toda columna con un hueco. Sí se eliminan las filas sin latitud, longitud o semáforo: sin coordenadas no hay agrupamiento y sin semáforo no se puede validar la calidad. Esas columnas no se imputan.

El Pipeline con imputación por mediana y escalado, al estilo del Laboratorio 1, se dejó como ejercicio de preparación de las variables de calidad. Esa matriz no entra a K-means ni se usa para las conclusiones.

2. Análisis exploratorio

Se revisaron tendencia central (media y mediana), dispersión (mínimo y máximo), posición (cuartiles y valores extremos) y correlación. DBO, DQO, SST, coliformes fecales y E. coli tienen sesgo positivo: la media queda muy por encima de la mediana porque unos pocos valores extremos jalan el promedio. En esas variables la mediana describe mejor el sitio típico. Oxígeno disuelto no se transformó, porque media y mediana ya se parecen y el dato es un porcentaje de saturación.

Las correlaciones se leen con cuidado: cada par de variables tiene distinta cantidad de sitios medidos. Un hueco no significa contaminación cero.

3. K-means y la relación con la ubicación

K-means se aplicó solo a longitud y latitud de los 3,493 sitios, en grados, sin escalarlas. La inercia queda en grados al cuadrado y no se lee como kilómetros. Se probaron varios valores de k. Se eligió $k = 4$ porque coincide con el codo de la inercia y da cuatro regiones que se pueden nombrar. $k = 2$ tiene la silueta más alta (0.503), pero parte el país en grupos demasiado grandes para el objetivo. Con $k = 4$ la silueta es 0.410: separación moderada. Un clúster es una región geográfica, no una etiqueta de agua buena o mala.

El semáforo no es igual en las cuatro regiones:

- Noroeste: 59.3 % verde y 18.0 % rojo.
- Occidente-Norte: 26.5 % verde y 30.2 % rojo.
- Centro-Golfo: 24.6 % verde y 43.8 % rojo.
- Sur-Península: 59.4 % verde y 15.7 % rojo.

Centro-Golfo concentra la mayor proporción de sitios rojos: cerca del 40 % de los sitios monitoreados y el 56 % de los semáforos rojos del país. Noroeste y Sur-Península son las regiones más verdes. Una prueba de independencia dio chi-cuadrado con 6 grados de libertad igual a 452.5 y $p < 0.001$. La V de Cramér fue 0.255. Hay asociación entre región y semáforo, pero es baja a moderada: la ubicación se relaciona con la calidad observada y no la determina sola.

4. Visualización

Los mismos sitios se muestran en el mapa de México de dos maneras: el contorno de cada clúster (la región que armó K-means) y el color del semáforo de cada punto. Los centroides marcan el centro de cada región. Si el mapa de regiones y el de colores se parecieran por completo, la ubicación bastaría para explicar la calidad. No es así: dentro de una misma región conviven verdes, amarillos y rojos, aunque las proporciones cambian de una región a otra.

5. Conclusiones

Sí hay una relación, estadísticamente significativa, entre la ubicación de los sitios y la calidad del agua superficial que CONAGUA monitoreó en 2020. Los porcentajes de verde, amarillo y rojo cambian entre las cuatro regiones. La fuerza de esa asociación es limitada. También intervienen el tipo de cuerpo de agua, la actividad humana, la cuenca y el hecho de que no todos los sitios se miden con los mismos parámetros.

El resultado es observacional: no demuestra causa. Corresponde a sitios de monitoreo de aguas superficiales en 2020. No representa todos los cuerpos de agua de México, no mide el agua potable de una casa y no alcanza, por sí solo, para decir en qué estado vivir ni si el agua se puede beber.

Notebook

El desarrollo está en el notebook del equipo. La versión usada para este reporte es `cd_final_proyecto.ipynb`. Ahí están la carga, la limpieza, el análisis exploratorio, K-means, el mapa y las conclusiones.

- Archivo:
https://github.com/marvinjc/proyecto_final_CD/blob/main/cd_final_proyecto.ipynb
- Repositorio: https://github.com/marvinjc/proyecto_final_CD

El enunciado acepta el enlace al notebook o el archivo `.ipynb`. Este documento se entrega junto con ese notebook.

Modalidad

Equipo. Integrantes: Charles Quesada Sandi, Aaron Chock Chock y Marvin Jesús Calvo Acuña.
Materia: Ciencias de Datos con Python. Profesor: Jorge Ariel Bermúdez Telleria. Fecha de la portada: 27 de septiembre de 2026.